



# Predicción de Cancelaciones de Reservas Hoteleras

*Clasificación con Redes Neuronales Artificiales*

BIG DATA — TRABAJO FINAL

UNIVERSIDAD PRIVADA DEL VALLE, BOLIVIA · 2025

Estudiante: **Amira Jimena Román Juchani** · Ingeniería en Ciencia de Datos y Negocios Inteligentes



# El Problema

La industria hotelera enfrenta pérdidas significativas por cancelaciones imprevistas: ineficiencia en recursos, habitaciones vacías y dificultad para gestionar disponibilidad en tiempo real.

## Optimizar Overbooking

Gestionar la sobreventa de forma controlada y segura.

## Maximizar Ocupación

Aumentar ingresos por habitación con planificación anticipada.

## Personalizar Políticas

Adaptar condiciones de cancelación según el perfil del cliente.



# Dataset: Hotel Booking Demand



## Ficha Técnica

**Fuente:** Antonio, Almeida & Nunes (2019)  
— *Data in Brief*, Vol. 22 · Kaggle

- **119,390 registros** · 32 variables originales
- Período: Julio 2015 – Agosto 2017
- Tipos: Resort Hotel y City Hotel
- Variable objetivo: `is_canceled` (0 = No, 1 = Sí)

Desbalance moderado (63:37),  
considerado en el diseño del modelo.

**63% No Cancelada**

75,166 reservas

**37% Cancelada**

44,224 reservas

# Análisis Exploratorio (EDA)

## Correlaciones con `is_canceled`

`lead_time` — +0.293

Mayor anticipación = mayor probabilidad de cancelación.

`total_of_special_requests` — -0.235

Más peticiones especiales = menor cancelación.


`previous_cancellations` — +0.110

Clientes con historial de cancelaciones repiten el patrón.

## Hallazgos Categóricos

- **deposit\_type:** Depósitos *Non Refund* muestran tasas ~99% (clasificación de reservas con restricciones estrictas).
- **market\_segment:** Las OTA presentan las mayores tasas; clientes corporativos son más estables.
- **customer\_type:** Los *Transient-Party* cancelan más que clientes de contrato o grupo.

# Preprocesamiento de Datos



Se eliminaron columnas con fuga de datos (`reservation_status`, `agent`, `company`) y se crearon 3 variables derivadas. El dataset pasó de 32 a 29 features finales. El escalado se ajustó **solo en train** para evitar fuga estadística.

# Red Neuronal Artificial — Arquitectura MLP

## Estructura del Modelo

Input (29) → Dense(128, ReLU) + BN + Dropout(0.3) → Dense(64, ReLU) + BN + Dropout(0.3) → Dense(32, ReLU) + Dropout(0.15) → Dense(1, Sigmoid)

- **14,977 parámetros** entrenables
- Optimizador: **Adam** (lr=0.001)
- Batch size: 512 · Epochs: 50
- Callbacks: EarlyStopping (paciencia=8) + ReduceLROnPlateau

## Regularización

### Dropout

30% en capas 1–2, 15% en capa 3. Previene sobreajuste.

### BatchNormalization

Estabiliza el aprendizaje y acelera la convergencia.

### EarlyStopping

Restaura los mejores pesos al monitorizar `val_loss`.

# Modelo Comparativo: Random Forest



## Configuración

- **200 árboles** · `max_depth=15`
- `min_samples_split=10` · `min_samples_leaf=5`
- `class_weight='balanced'` para compensar desbalance

## Variables más influyentes (Feature Importance)

1. `lead_time` — tiempo de anticipación
2. `adr` — tarifa diaria promedio
3. `total_of_special_requests`
4. `deposit_type` y `previous_cancellations`

Resultados coherentes con las correlaciones del EDA y la intuición del negocio hotelero.



# Resultados — Conjunto de Prueba

Evaluación sobre **23,878 muestras** (20% del dataset).

| Métrica            | RNA (MLP) | Random Forest | Diferencia |
|--------------------|-----------|---------------|------------|
| Accuracy           | 86.34%    | 86.57%        | RF +0.23%  |
| F1-Score (clase 1) | 0.8081    | 0.8196        | RF +0.0115 |
| ROC-AUC            | 0.9419    | 0.9424        | RF +0.0005 |
| Recall Cancelada   | 0.78      | 0.82          | RF +0.04   |

86.34%

Accuracy RNA

+23 pts sobre baseline trivial (63%)

0.9419

AUC-ROC RNA

Discriminación excelente

0.78

Recall Cancelada


Métrica operativamente más relevante



# Análisis e Interpretación

## Implicaciones de los Errores

El **Random Forest** es marginalmente superior en Recall (0.82 vs 0.78), haciéndolo más recomendable operacionalmente. Las diferencias globales son mínimas (<0.5%).



### Falso Positivo

Predice cancelación pero la reserva se mantiene → Riesgo de sobreventa.

### Falso Negativo ⚠

No predice cancelación pero sí ocurre → **Habitación vacía, pérdida directa de ingresos.** Más crítico para el negocio.

# Conclusiones y Próximos Pasos

## Aprendizajes Clave

### → Preprocesamiento crítico

Eliminar fuga de datos y escalar correctamente fue determinante.

### → RNA con alta capacidad predictiva

MLP 128→64→32 alcanzó 86% accuracy y 0.94 AUC-ROC.

### → Predictores clave

`lead_time`, `total_of_special_requests` y `deposit_type` son los más influyentes.

## Mejoras Futuras

- Balanceo de clases con **SMOTE** para mejorar Recall.
- Explorar **XGBoost** / **LightGBM** como comparación adicional.
- Implementar **SHAP values** para explicabilidad de la RNA.
- Incorporar variables externas: festivos, eventos, condiciones económicas.
- Desplegar en sistema de **scoring en tiempo real**.